

PROYECTO 2 · VISIÓN COMPUTACIONAL CON DEEP LEARNING

MinneApple

Detección, segmentación y atención para estimar la cosecha
de manzana

Alejandro Galvez · Joan Sebastian Mena · Maria Estella Fuentes · Sergio Luis Castaño

Maestría en Inteligencia Artificial y Ciencia de Datos · Universidad Autónoma de Occidente · Sustentación: 3 de octubre de 2026

Estimar la cosecha a ojo es impreciso

El agricultor necesita contar y medir la fruta antes de cosechar, para planear transporte, almacenamiento y personal. Un cálculo errado genera desperdicio de fruta o falta de capacidad logística.



Detectar

Contar cada manzana visible en la foto, con una caja



Segmentar

Separar cada una del fondo para medir su tamaño real



Explicar

Mostrar en qué se fija el modelo (self-attention y Grad-CAM)

MinneApple: fotos reales de un huerto

Licencia

CC BY-NC-SA 3.0 US · Universidad de Minnesota, 2019

Imágenes


670 de entrenamiento + 331 de test oficial

Captura

Cámara de celular, huerto real, 2015-2016

El reto


75-89% de las manzanas mide menos de 32×32 px



La densidad de manzanas varía mucho entre videos (22 a 98 por imagen):
se parte train/val por video completo, nunca por foto

Un solo modelo, con self-attention


- ✓ YOLO11-seg preentrenado en COCO, ajustado a MinneApple: detección y segmentación de instancias a la vez
- ✓ Self-attention: bloque C2PSA en la capa 10 del backbone
- ✓ Ablación: la misma arquitectura, con esa capa reemplazada por Identity, para medir qué aporta la atención



Las dos variantes difieren solo en la capa 10

Aislar cada manzana para medirla

- ✓ Máscara de instancia → recorte con fondo transparente
- ✓ Diámetro en píxeles; en mm y peso si el usuario da una escala
- ✓ Color descriptivo (rojo / verde-amarillo) — no es madurez



Las 12 manzanas más grandes de una foto real, aisladas del fondo

Grad-CAM: ¿dónde mira el modelo, con y sin atención?



sin C2PSA

73% de la atención
dentro de las
manzanas

con C2PSA

86% de la atención
dentro de las
manzanas

Resultados en test

Modelo final: small + C2PSA, 1280 px · evaluado una sola vez, 331 fotos

Métrica	Modelo final (test)
mAP@0.5:0.95 (caja)	0,48
mAP@0.5:0.95 (máscara)	0,35
Dice de la unión	0,78
Error de conteo por foto	5,4 manzanas

Comparación con y sin self-attention (bootstrap pareado, 993 pares): **sí se confirma** — mejora el Dice (+0,017) y el conteo (1,9 manzanas menos de error). En validación, con menos datos, no se distinguía del ruido.

Optimización, tiempos y despliegue

Optimización (INT8)

Tamaño: 39,2 → 14,9 MB (**-62 %**)

Validación: cumple el límite fijado antes de medir (perder como mucho 0,02 de mAP)

Test: **no lo cumple** (-0,044) y ve 9,5 manzanas de más por foto. La app usa el modelo original

Tiempos (mediana)

Red sola: 120 ms en GPU frente a 846 ms en CPU (**7× más rápida**)

La app, por foto: 0,3 s en GPU y 1 s en CPU

INT8 en CPU: solo 1,2× más rápido que el original

Despliegue

App en Streamlit: subir una foto o usar la cámara

Cloudflare Tunnel, para probarla desde cualquier celular

Candado (Lock) para varios usuarios a la vez, ya probado

En resumen

- ✓ Un modelo, tres tareas: detección, segmentación y atención, sobre fotos reales de huerto
- ✓ Método: partición por video, criterios fijados antes de medir, trazabilidad completa
- ✓ App en vivo con Streamlit y Cloudflare Tunnel
- 💡 Mejora futura: YOLO26 iguala o supera estos resultados con un tercio de los parámetros

Gracias — preguntas

MinneApple · Sustentación: 3 de octubre de 2026